

Dominando el Paquete survey en R

Teoría, Diseños Muestrales Complejos y Modelado Estadístico

Estadística y Ciencia de Datos

24 de agosto de 2026

Contenido Generales

- I. Fundamentos del Muestreo Complejo
- II. Especificación por Tipo de Diseño
- III. Estimaciones Estadísticas
- IV. Modelado Avanzado: `svyglm()`
- V. Trampas Frecuentes y Buenas Prácticas

I. Fundamentos del Muestreo Complejo

¿Por qué fallan los métodos convencionales?

Los métodos clásicos (lm, glm, mean) asumen que las observaciones son **Independientes e Idénticamente Distribuidas (i.i.d.)**.

En encuestas reales, el diseño rompe esta hipótesis debido a:

- **Desproporción en la selección:** No todos los individuos tienen la misma probabilidad de ser elegidos.
- **Agrupamiento geográfico o institucional:** Las unidades de un mismo colegio o manzana se parecen entre sí (correlación intraclase).
- **Estratificación:** Se fuerza representación en subpoblaciones.

El peligro práctico

Ignorar el diseño no afecta necesariamente la estimación puntual, pero **subestima drásticamente los Errores Estándar**, generando p-valores falsamente significativos.

Los Tres Componentes de `svydesign()`

La función central del paquete `survey` traduce la estructura del diseño muestral mediante 3 conceptos clave:

Pesos (w_i): Inverso de la probabilidad de selección ($w_i = 1/\pi_i$).

Representan a cuántos individuos de la población equivale cada fila.

Estratos (`strata`): Divisiones homogéneas de la población. **Reducen** la varianza de las estimaciones.

Conglomerados (`ids`): Unidades Primarias de Muestreo (UPM).

Aumentan la varianza debido al efecto de diseño ($Deff$).

Parámetro Crucial: `nest = TRUE`

Obligatorio cuando las claves de las USM (etapa 2) se repiten entre distintas UPMs (etapa 1).

II. Especificación por Tipo de Diseño

1. Muestreo Aleatorio Simple (MAS) y Pesos

```
1 library(survey)
2 # Configuraci3n global preventiva para estratos con 1 sola UPM
3 options(survey.lonely.psu = "adjust")
4
5 # MAS sin ponderar (Probabilidades iguales:  $w_i = 1$ )
6 disen3o_mas <- svydesign(ids = ~1, data = datos)
7
8 # MAS con Pesos de Horvitz-Thompson
9 disen3o_mas_pesos <- svydesign(
10   ids = ~1,
11   weights = ~peso,
12   data = datos
13 )
14
15 # Estimaci3n de la media ponderada
16 svymean(~ingreso, disen3o_mas_pesos)
17
```

2. Muestreo Estratificado y Conglomerados

```
1 # Muestreo Estratificado (Estratificación directa)
2 disen0_estratificado <- svydesign(
3   ids = ~1,
4   strata = ~region,
5   weights = ~peso,
6   data = datos
7 )
8
9 # Muestreo por Conglomerados en una etapa (UPM)
10 disen0_conglomerados <- svydesign(
11   ids = ~colegio_id,
12   weights = ~peso,
13   data = datos
14 )
15
16 # Estratificado y Conglomerados Combinado
17 disen0_estrat_cong <- svydesign(
18   ids = ~colegio_id,
19   strata = ~region,
20   weights = ~peso,
21   data = datos,
22   nest = TRUE
23 )
24
```


3. Diseño Multietápico Completo

Muestreo con selección jerárquica: UPM (Etapa 1) y USM (Etapa 2) anidadas en estratos.

```
1 # Muestreo Multietápico (Estratificado + UPM + USM + Pesos)
2 disenio_multietapico <- svydesign(
3   ids = ~municipio_id + sector_id, # UPM (Etapa 1) + USM (Etapa 2)
4   strata = ~departamento_id, # Estratificación poblacional
5   weights = ~peso_expansion, # Ponderación muestral
6   data = datos,
7   nest = TRUE # Garantiza anidamiento jerárquico
8 )
9
10 # Resultado de la media en el diseño complejo
11 svymean(~gasto_total, disenio_multietapico)
12
```

III. Estimaciones Estadísticas

Traducción de Funciones Estándar a survey

Análisis	R Base	Paquete survey
Media	<code>mean(x)</code>	<code>svymean(~x, diseno)</code>
Total Poblacional	<code>sum(x)</code>	<code>svytotal(~x, diseno)</code>
Cuantiles / Mediana	<code>quantile(x)</code>	<code>svyquantile(~x, diseno,</code>
Tablas Cruzadas	<code>table(x, y)</code>	<code>svytable(~x + y, diseno)</code>
Medias por Dominio	<code>tapply(x, g, mean)</code>	<code>svyby(~x, ~g, diseno, sv</code>

Análisis por Dominios y Filtros de Submuestras

Regla Crítica: ¡Nunca uses `subset()` sobre la base de datos!

Si filtras el *data frame* de R directamente antes de definir el diseño, destruyes la estructura de los estratos/conglomerados y calculas mal los Errores Estándar.

```
1 # FORMA CORRECTA: Filtrar sobre el OBJETO DE DISEÑO
2 disen0_mujeres <- subset(disen0_multietapico, genero == "Femenino")
3 svymean(~ingreso, disen0_mujeres)
4
5 # ALTERNATIVA: Estimación por grupos usando svyby()
6 svyby(
7   formula = ~ingreso,
8   by = ~nivel_educativo,
9   design = disen0_multietapico,
10  FUN = svymean
11 )
12
```

IV. Modelado Avanzado:

`svyglm()`

Regresión Lineal y Logística Ponderada

svyglm() implementa la estimación por **Pseudo-Máxima Verosimilitud** ajustando los errores estándar mediante matriz Sandwich (Linearización de Taylor).

```
1 # Regresión Lineal Compleja
2 mod_lineal <- svyglm(
3   log(ingreso) ~ educacion + experiencia + horas,
4   design = diseno_multietapico
5 )
6 summary(mod_lineal)
7
8 # Regresión Logística
9 mod_logistico <- svyglm(
10  pobreza ~ educacion + tamaño_hogar,
11  design = diseno_multietapico,
12  family = quasibinomial() # IMPORTANTE: Previene advertencias de dispersión
13 )
14 summary(mod_logistico)
15
```

V. Trampas Frecuentes y Buenas Prácticas

Lista de Comprobación para Análisis de Encuestas

1. **Copia Estática:** El objeto `svydesign` guarda una copia estática del *data frame*. Crea tus variables numéricas o dicotómicas **antes** de declarar el diseño.
2. **Lonely PSUs:** Incluye siempre al inicio:
`options(survey.lonely.psu = .adjust")` para solucionar estratos con solo una UPM muestreada.
3. **Familias GLM:** Usa `family = quasibinomial()` en modelos logísticos para evitar advertencias por no usar enteros exactos en pesos expandidos.
4. **Diseños de Replicación:** Si la encuesta proporciona pesos pesados/pesos de réplica (BRR, Jackknife, Bootstrap), utiliza `svrepdesign()` en lugar de `svydesign()`.

¡Gracias!

Preguntas y Discusión